실습으로 배우는 신약개발 AI

김 화 종

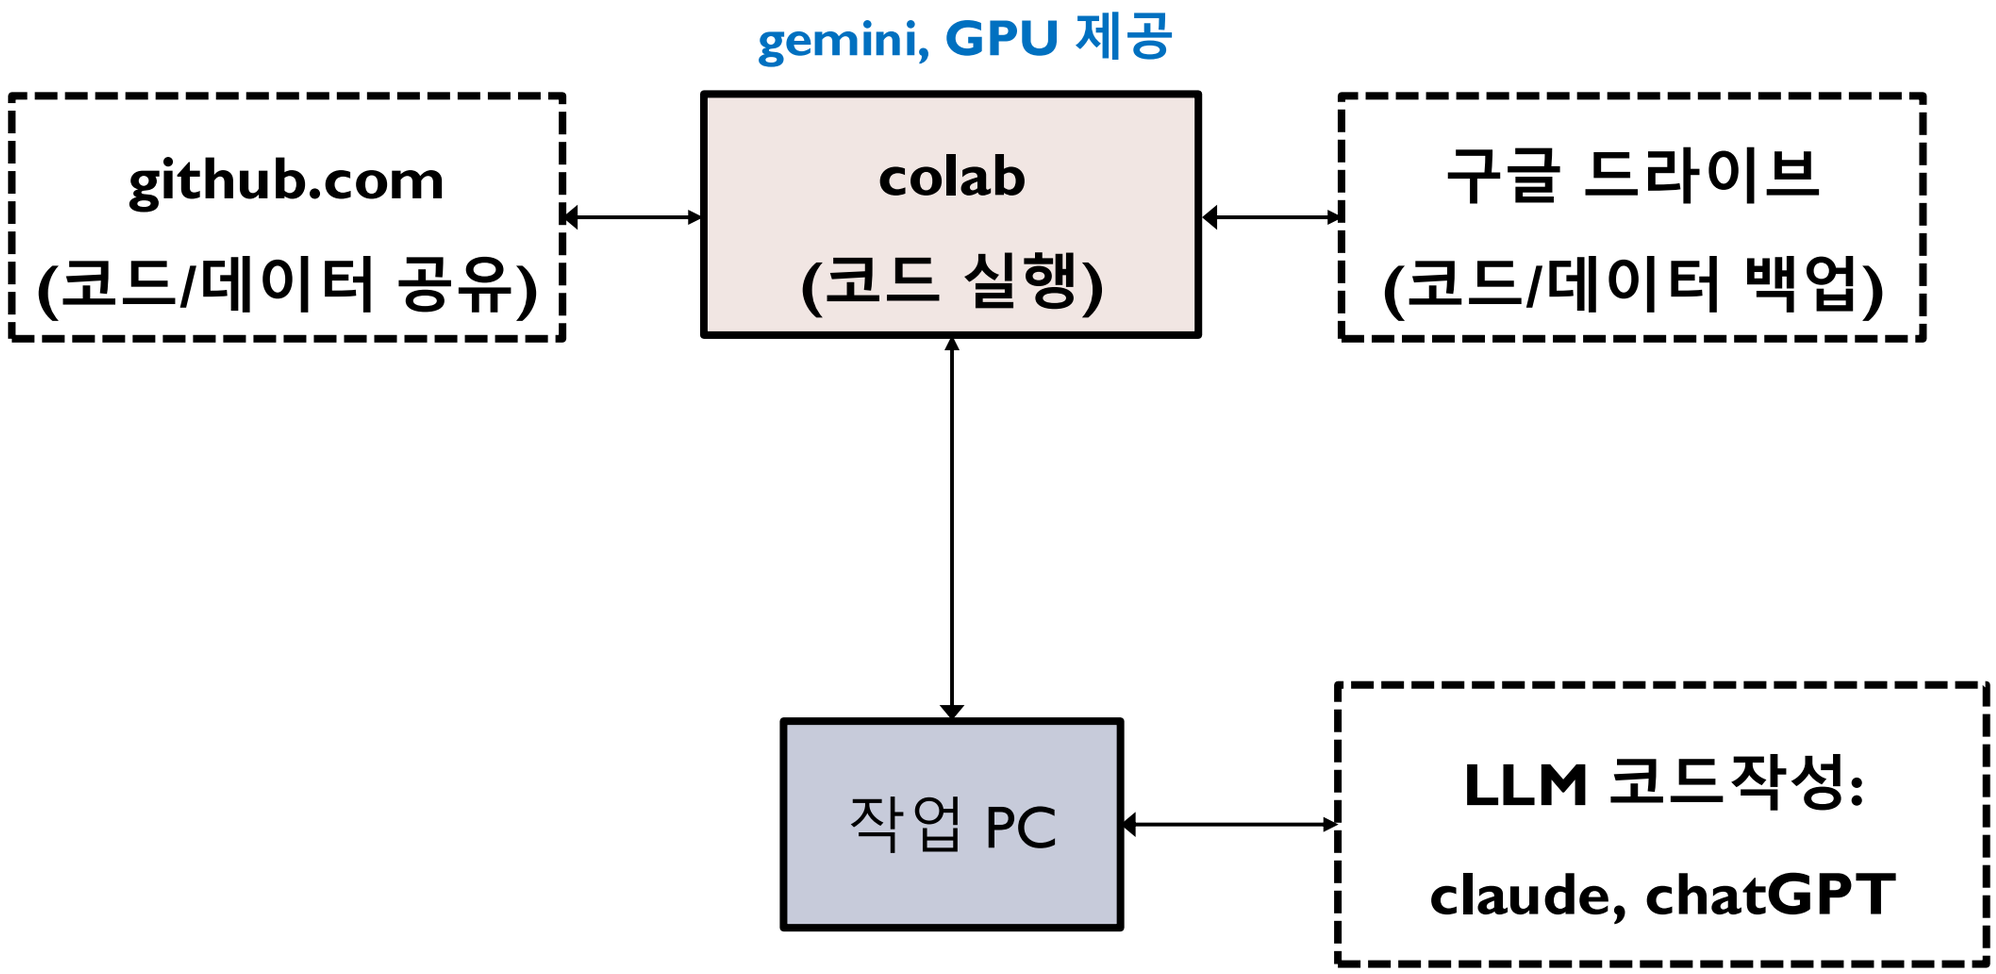
K-MELLODDY 사업단장

hjkim3@gmail.com

강의 내용

- 신약개발 프로세스와 AI 적용
- 화합물 데이터 다루기 – SMILES와 분자 표현형
- LLM 코딩으로 만드는 AI 모델
- 머신러닝 모델 유형과 성능 비교
- 용해도 예측 회귀 모델(QSAR)
- 독성 예측분류 모델
- 딥러닝 모델 유형 비교
- 모델 최적화 – 특성공학과 하이퍼파라미터 튜닝
- 가상 스크리닝과 분자 도킹
- 단백질 구조 예측
- 신약 타겟 발굴- 오믹스·네트워크 데이터
- 생성형 AI 기반 신약 분자 설계

실습 환경


gemini, GPU 제공
github.com
(코드/데이터 공유)
colab
(코드 실행)
구글 드라이브
(코드/데이터 백업)
작업 PC
LLM 코드작성:
claude, chatGPT

신약개발 프로세스와 AI

1 질병 이해·타깃 발굴

오믹스 분석 · 질병 아형 · 바이오마커 · 타깃 예측/검증

2 후보물질 발굴·최적화

가상 스크리닝 · 생성형 분자 설계 · 구조예측(AlphaFold) · ADMET

3 전임상(비임상)

독성 예측 · PK/PD 모델링 · 효능 예측 · 동물실험 대체

4 임상

임상시험 설계 · 코호트 선별 · 디지털 바이오마커 · 약물감시

5 CMC·제조·품질

QbD · 공정 이상탐지 · OOS 예측 · RTRT · 예지보수

6 규제·허가

문서 자동화(eCTD) · FDA/EMA 대응 · GAIP · 모델 검증

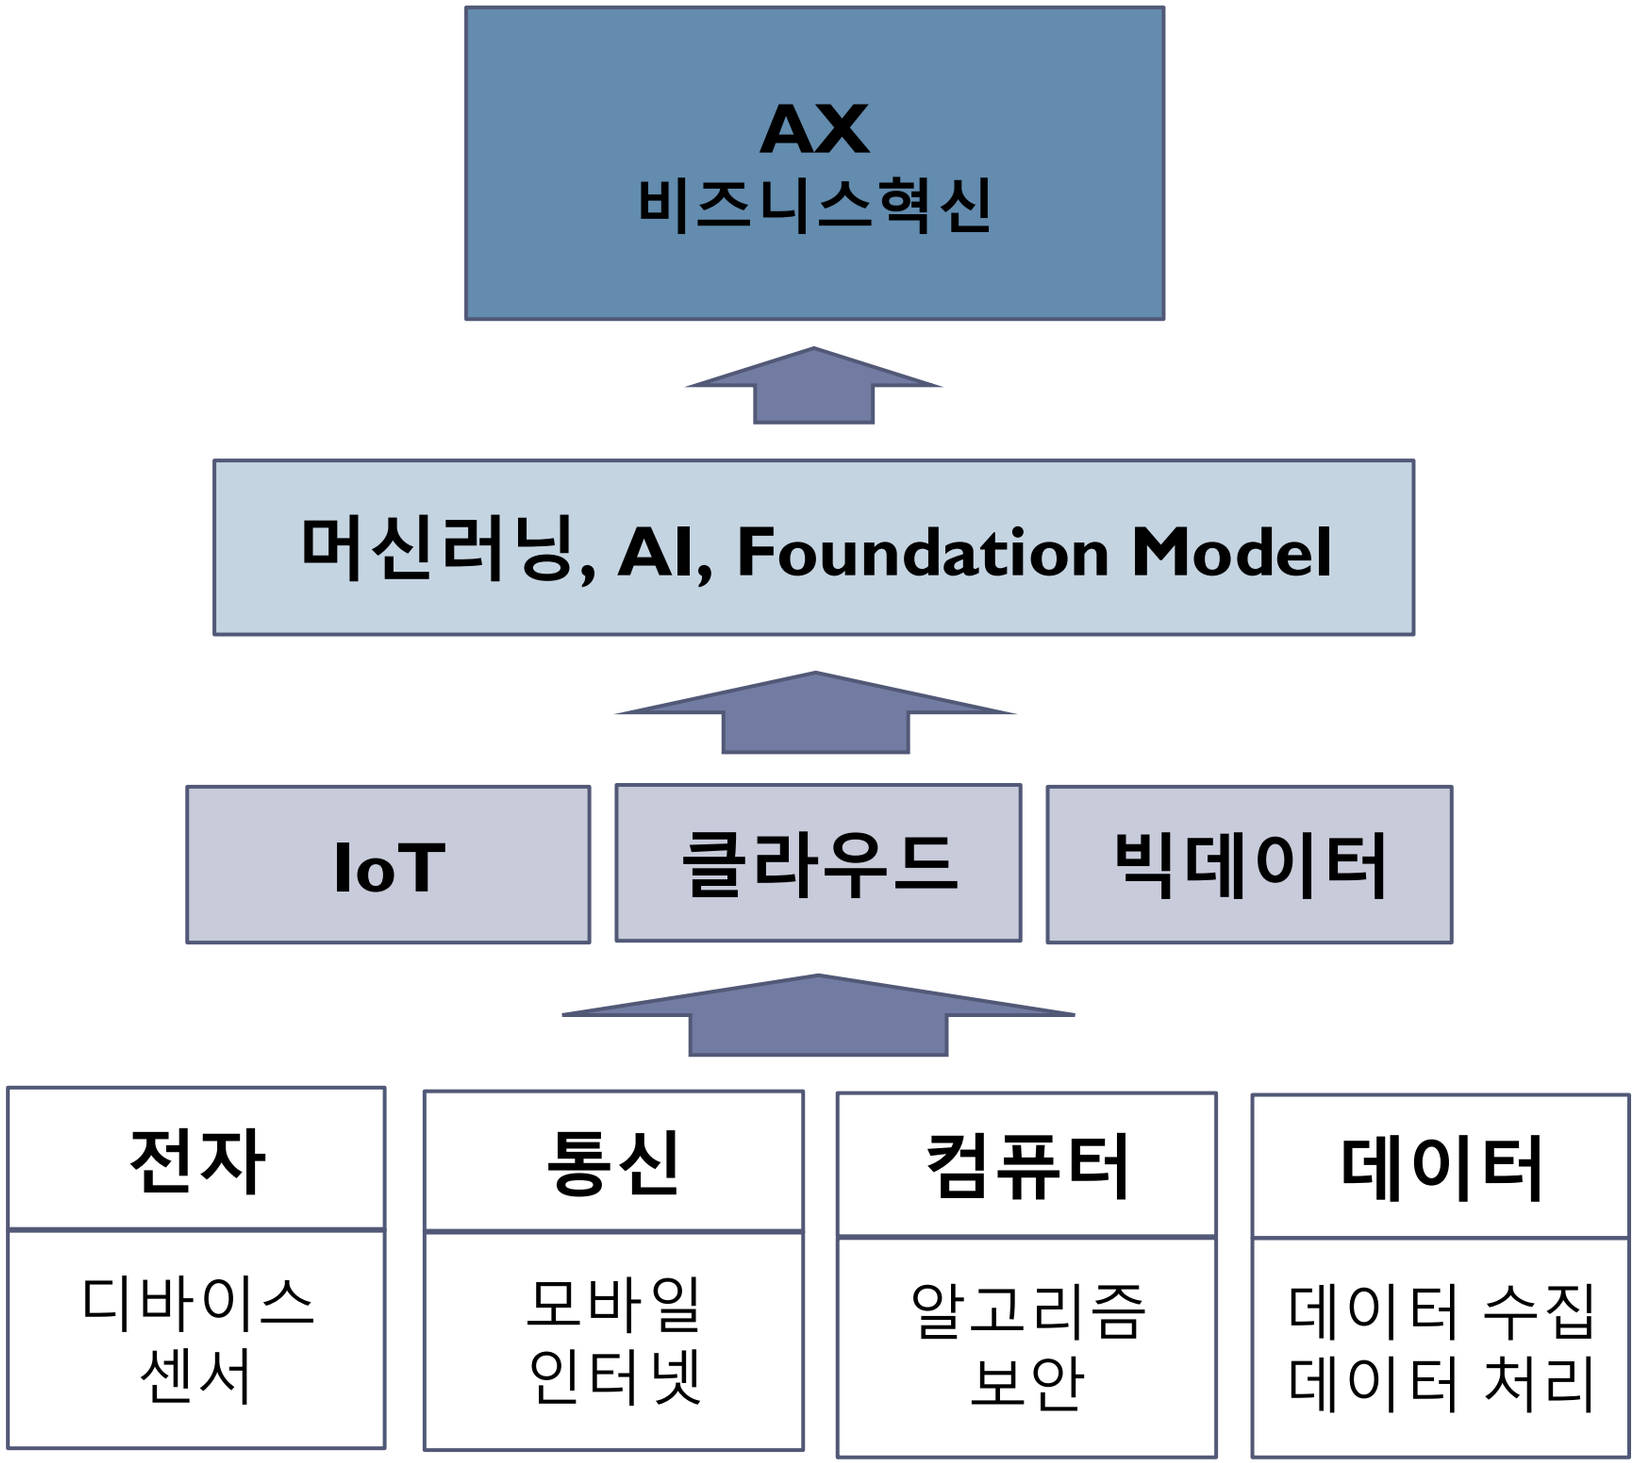
7 시판 후

RWE/RWD 분석 · 시판후 안전성 · 시장·환자 인사이트

공통 기술 (파운데이션)

예측형 · 생성형 AI · 연합학습(K-MELLODDY) · 파운데이션 모델 · 멀티모달

AX (AI Transformation)



머신러닝 (machine learning)

- AI 구현의 기반 기술
  - 컴퓨터가 (인간처럼) 데이터를 보고 **스스로** 학습한다
- 사람의 지식이 개입되지 않는, **end-to-end 방식**으로 동작
  - 논리적인 해석이나 중간 값 확인을 필요로 하지 않는다
  - 사람은 **학습하는 기계**를 발명한 것

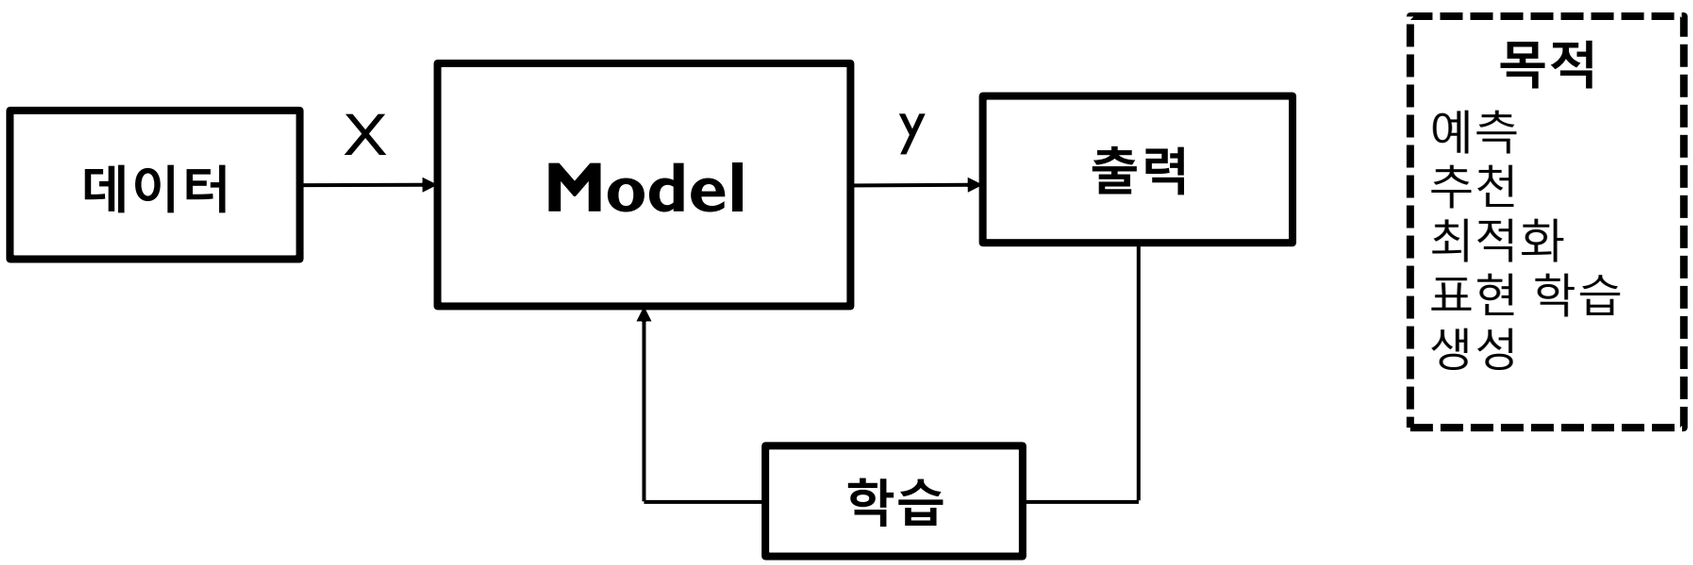
AI 범위

머신러닝	딥러닝	AI	LLM	파운데이션 모델	FM 활용	AX
확률 기반 지도학습 비지도학습	신경망 (CNN/RNN) 표현 학습	Transformer Attention 메커니즘	GPT · BERT 수십억 파라미터	멀티모달 제로샷 / 퓨샷	RAG Fine-tuning Prompt Eng.	AI 에이전트 조직·업무 재설계
스팸 필터 추천 시스템	이미지 인식 음성 인식	기계 번역 감성 분석	챗봇 · QA 문서 요약	이미지 생성 멀티모달 검색	기업 지식검색 AI 코파일럿	산업 AI 전환 비즈니스 혁신

※ AX(AI Transformation): AI 기술을 통한 업무·비즈니스 전반의 구조적 전환

AI Model

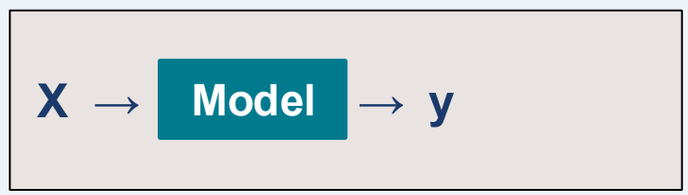
- AI 구현의 핵심은, 데이터(X)로부터 원하는 출력(y)를 생성하는 모델(Model) SW 개발이다
- 수식은 가장 명쾌한 모델이나 생명현상을 포함한 복잡한 실제 세계를 모델링하는데 한계가 있다
- 데이터를 기반으로 동작하는 **Machine Learning Model**이 현재 AI 구현에 널리 사용되고 있다
  - 데이터: 학습 데이터, 검증 데이터, 테스트 데이터



AI Model 유형

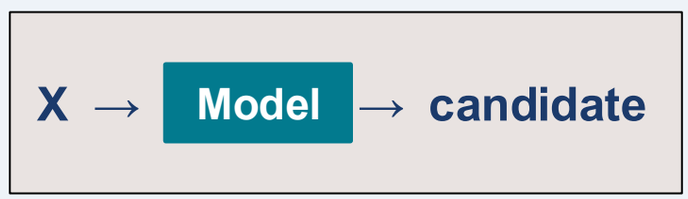
예측 모델
Predictive Model

입력 데이터(X, feature)를 보고 출력(y, 레이블) 예측
→ **이상치(OOS) 예측, 배치 품질 예측**



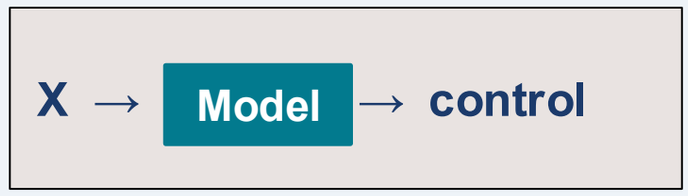
추천 모델
Recommender Model

최적의 상품·처방·후보 추천
→ **신약 후보 추천, CAPA(시정 및 예방 조치) 대응책 추천**



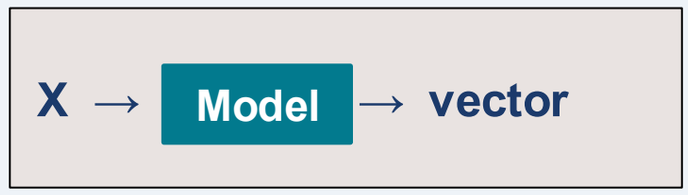
최적화 모델
Prescriptive Model

현재 조건(X)에서 최적 설계·제어 변수 도출
→ **공정 핵심변수(CPP) 최적화, 배합 최적 설계**



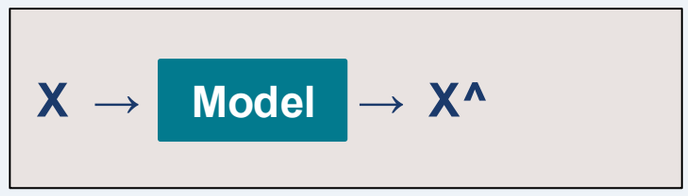
표현 학습
Representation Learning

X를 학습하여 의미 있는 벡터 표현(embedding) 학습
→ **파운데이션 모델(LLM), 분자 임베딩**



생성 모델
Generative Model

파운데이션 모델을 이용하여 원하는 데이터(X^) 생성
→ **자연어 처리, 분자 생성 모델, 단백질 구조 생성**



AI 구현 체계

데이터

정형 데이터

텍스트

이미지, 동영상

센서

분자/단백질 표현형

데이터 전처리

x

머신러닝, 딥러닝 모델

Linear Model, SVM, Logistic Regression

Random Forest, Tree, Boost

MLP

CNN

RNN / LSTM

Graph Neural Net

Transformer

y

AI 목적

예측 (회귀, 분류)

추천

최적화

생성

표현 학습, 클러스터링

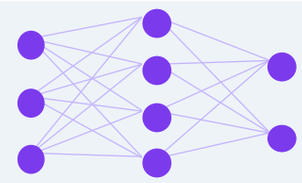
머신러닝 모델

머신러닝 유형		알고리즘	특 징
지도학습 (y가 존재)	선형 계열	선형 모델, SVM 로지스틱회귀	곱셈과 덧셈으로 점수를 구하고 이를 이용하여 회귀와 분류 예측
	신경망	MLP, CNN, RNN, Transformer Graph Network	매트릭스 연산을 기반으로 점수를 계산하며 활성화 함수 도입
	트리 계열	결정 트리, 랜덤포레스트, 부스팅	True/False 선택을 반복하여 회귀와 분류 예측 수행. 스케일링이 필요없다
	기타	kNN, 베이즈	특성 공간상의 거리를 기준, 또는 조건부 확률을 기준으로 예측
비지도학습 (y가 없음)	클러스터링	k-means, DBSCAN	특성 공간상 거리 또는 유사도를 기준으로 샘플을 그루핑
	데이터 변환	스케일링, 로그변환, 카테고리 인코딩	모델의 성능을 높이 위한 데이터 전처리
	차원 축소	PCA, t-SNE	계산량을 줄이고 모델 성능을 향상, 또는 시각화를 위한 차원 축소
	표현 학습	LLM 등 파운데이션 모델	입력 데이터를 latent vector로 표현하는 비지도 학습
강화학습		시행착오의 경험을 누적	샘플 입력마다 정답이 있지 않지만 최종적으로 달성해야 할 목표를 알려주고 보상을 통해 학습

딥러닝 모델

MLP

Multi Layer Perceptron. 완전 연결(Fully Connected) 레이어들의 다층 구조로 **비선형적인** 입출력 관계 예측에 주로 사용



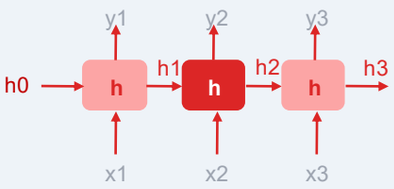
CNN

Convolution Neural Network. 2차원 이미지, 1차원 시계열 데이터의 **패턴 추출**에 주로 사용



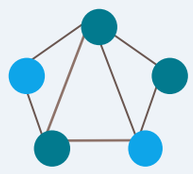
RNN (LSTM)

Recurrent Neural Network (Long Short Term Memory). 순환 구조로 **시퀀스 데이터**· 텍스트 분석 · SMILES 분석 등에 활용



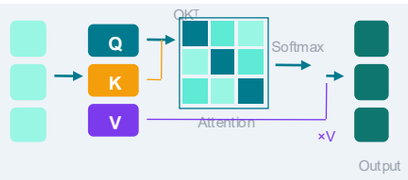
Graph Model

노드와 엣지로 구성된 그래프 형태의 모델로 **분자 구조**, 사회관계망 등의 분석에 사용



Transformer

입력 시퀀스를 블록 단위로 나누어 Self-Attention을 계산하는 방식으로 텍스트, 시퀀스 데이터의 **문맥 파악** 성능을 향상. LLM의 성능 고도화 (BERT, GPT)



표현 학습

표현 (Representation)

X				y
이름	키	몸무게	나이	운동종목
A	178	73	34	축구
B	169	72	38	탁구
C	173	68	52	농구
…	…	…	…	…
Z	175	82	29	배구

- X: features, 설명변수, 독립변수, 입력 → **표현(representations)**
- y: label, 목적변수, 종속변수, 출력

Image Representation

- 몽타주는 이미지를 수십개의 features(숫자)로 표현하는 것
  - 안경:0, 눈썹길이:0.8, 눈썹모양: 2, 코:0.7, 입술:0.4, 턱: 0.4, 귀:3,…
- 얼굴 = (0, 0.8, 2, 0.7, 0.4, 0.4, 3, …, 0,6) : vector
  - → 이미지를 임베딩 벡터로 표현 가능
  - → 벡터 **차원을 높이면** 매우 정교하게 얼굴을 묘사할 수 있다
  - → 벡터 **값을 바꾸면** 다른 얼굴을 표현할 수 있다 (이미지 생성 모델)

이미지 임베딩 벡터 연산

단어 임베딩

- 예를 들어 왕:여왕 = 아들:?에서 ? 부분이 딸이 될 것이다.

Word Representation

- word embedding vector 표현 (300~1000 차원 사용)
- 단어 사이의 **거리**가 의미가 있다
- 단어 간의 **방향**이 의미가 있다

사람-영화 임베딩 벡터

- 영화 평점 데이터로부터 사람과 영화를 각각 고차원 공간의 벡터로 표현할 수 있다
  - 비슷한 사람은(영화는) 비슷한 벡터 값(위치)을 갖는다
- 고차원 벡터를 행렬 분해(Matrix Decomposition)를 하여 저차원으로 줄여 '사람 임베딩'과 '영화 임베딩'을 구할 수 있다
  - 모든 영화에 대한 평점이 필요한 것은 아니다

word2vec

- 단어를 임베딩 벡터로 환산하는 (학습시키는) 방법
- 괄호 넣기 문제

Language Model

- 언어 모델(Language Model)
  - 단어들이 나열된 후 다음에 나타날 가장 적절한 단어들의 확률을 계산하는 모델
  - 컴퓨터 프로그램도 언어 모델로 작성한다
- LLM (Large Language Model)
  - 공개된 대량의 텍스트를 사용하여 **사전 학습**시킨 모델
  - Foundation 모델이라고도 한다
  - BERT(구글), GPT(Generative Pretrained **Transformer**, OpenAI)
- Bio LLM
  - 원자 시퀀스로 구성된 분자, 또는 아미노산 시퀀스로 구성된 단백질을 언어 모델로 분석할 수 있다
  - MoLer (MS) – Structural Motif 생성
  - BioNeMo(OpenAI) – LLM 기반 DTI
  - Protein Language Model

Foundation Model

Foundation Model

- 대표적 예: Large Language Model
- 파운데이션 모델 성능 개선
  - prompt engineering – 지시문을 효과적으로 제시
  - RAG(retrieval-augmented generation) – 추가 학습 데이터를 제공
  - Fine tuning – 정밀 재학습
- 파운데이션 모델 활용
  - agentic AI

LLMs

모델명	개발사	특 징
ChatGPT	OpenAI	가장 널리 사용됨. 다양한 응답 능력과 API 제공. 추론, 코딩, 창작 가능
Claude	Anthropic	인간 중심의 안전성과 윤리성을 강조. 긴 컨텍스트 처리 능력
Gemini	Google DeepMind	웹 검색과 통합된 기능 제공. 이미지 분석과 생성에 우수
LLaMA	Meta (Facebook)	오픈소스에 가까운 모델로 연구 및 커스터마이징 용이. 파라미터 크기 (7B, 13B, 70B)
Mistral/ Mixtral	Mistral AI	빠르고 효율적인 오픈 소스 모델. Mixtral은 mixture-of-experts 구조 채택

Bio Foundation Model

Bio LLMs

모델명	개발기관	주요 용도	신약개발 활용
ESM (Evolutionary Scale Modeling)	Meta AI	단백질 구조 예측, 돌연변이 영향 예측	단백질 안정성, 후보 물질 타겟 분석
AlphaFold	DeepMind	단백질 3D 구조 예측	구조 기반 약물설계, docking
ProtTrans	TU Munich 등	단백질 서열 임베딩, 기능 예측, 효소 분류	단백질 후보 특성 분석
Geneformer	Broad Institute	세포 표현형 기반 유전자 조절 네트워크 분석	표적 유전자 발굴, 세포 반응 예측
MolFormer	Salesforce Research	분자 표현(embedding), 물성 예측, 활성 예측, virtual screening	QSAR, 분자 최적화, docking 전 필터링

Foundation Model for Drug Discovery

Pipeline	Key Tasks	Foundation Models
Target Identification & Validation	• Decode disease biology • Reveal druggable proteins & pathways	**Enformer** (genome-wide variant-to-expression) **AlphaFold** (atomic-level protein-structure predictor) **ESM** (large protein-language model)
Hit & Lead Discovery	• docking & binding-pose ranking • Generative exploration	**DiffDock** (diffusion-based ligand-docking generator) **Graphormer** (property / binding scoring) **MolFormer** (SMILES & graph molecule generation)
Lead Optimization	• Improve potency, selectivity • Engineer novel biologics	**ProGen 3** (billion-param protein-generation LM) **ChemBERTa-2** (large chemical LMs for SAR prediction) **ProteinMPNN** (sequence-to-structure fine-tuning)
Pre-clinical Safety & PK/PD	• ADME-Tox screening • PK/PD forecasting	**ADMETlab 2.0** (comprehensive ADMET predictor) **DeepTox / ToxBERT** (toxicity LMs) **BioTransformer** (metabolite & biotransformation)
Clinical Trail	• Patient stratification • trial simulation	**Med-PaLM** (multimodal medical LLM) **BEHRT** (EHR-sequence Transformer for risk prediction) **GatorTron** (8.9 B-parameter clinical language model)

Multi Modality

- 이미지와 텍스트를 동시에 학습 (2023~)
  - Large Multimodal Model

- CLIP (Open AI 2021)
  - Contrastive Language–Image Pre-training
  - 추가 학습 없이도 이미지 분류 작업을 수행
  - 이후 Flamingo, LLaVA, Gemini 등 소개

CLIP

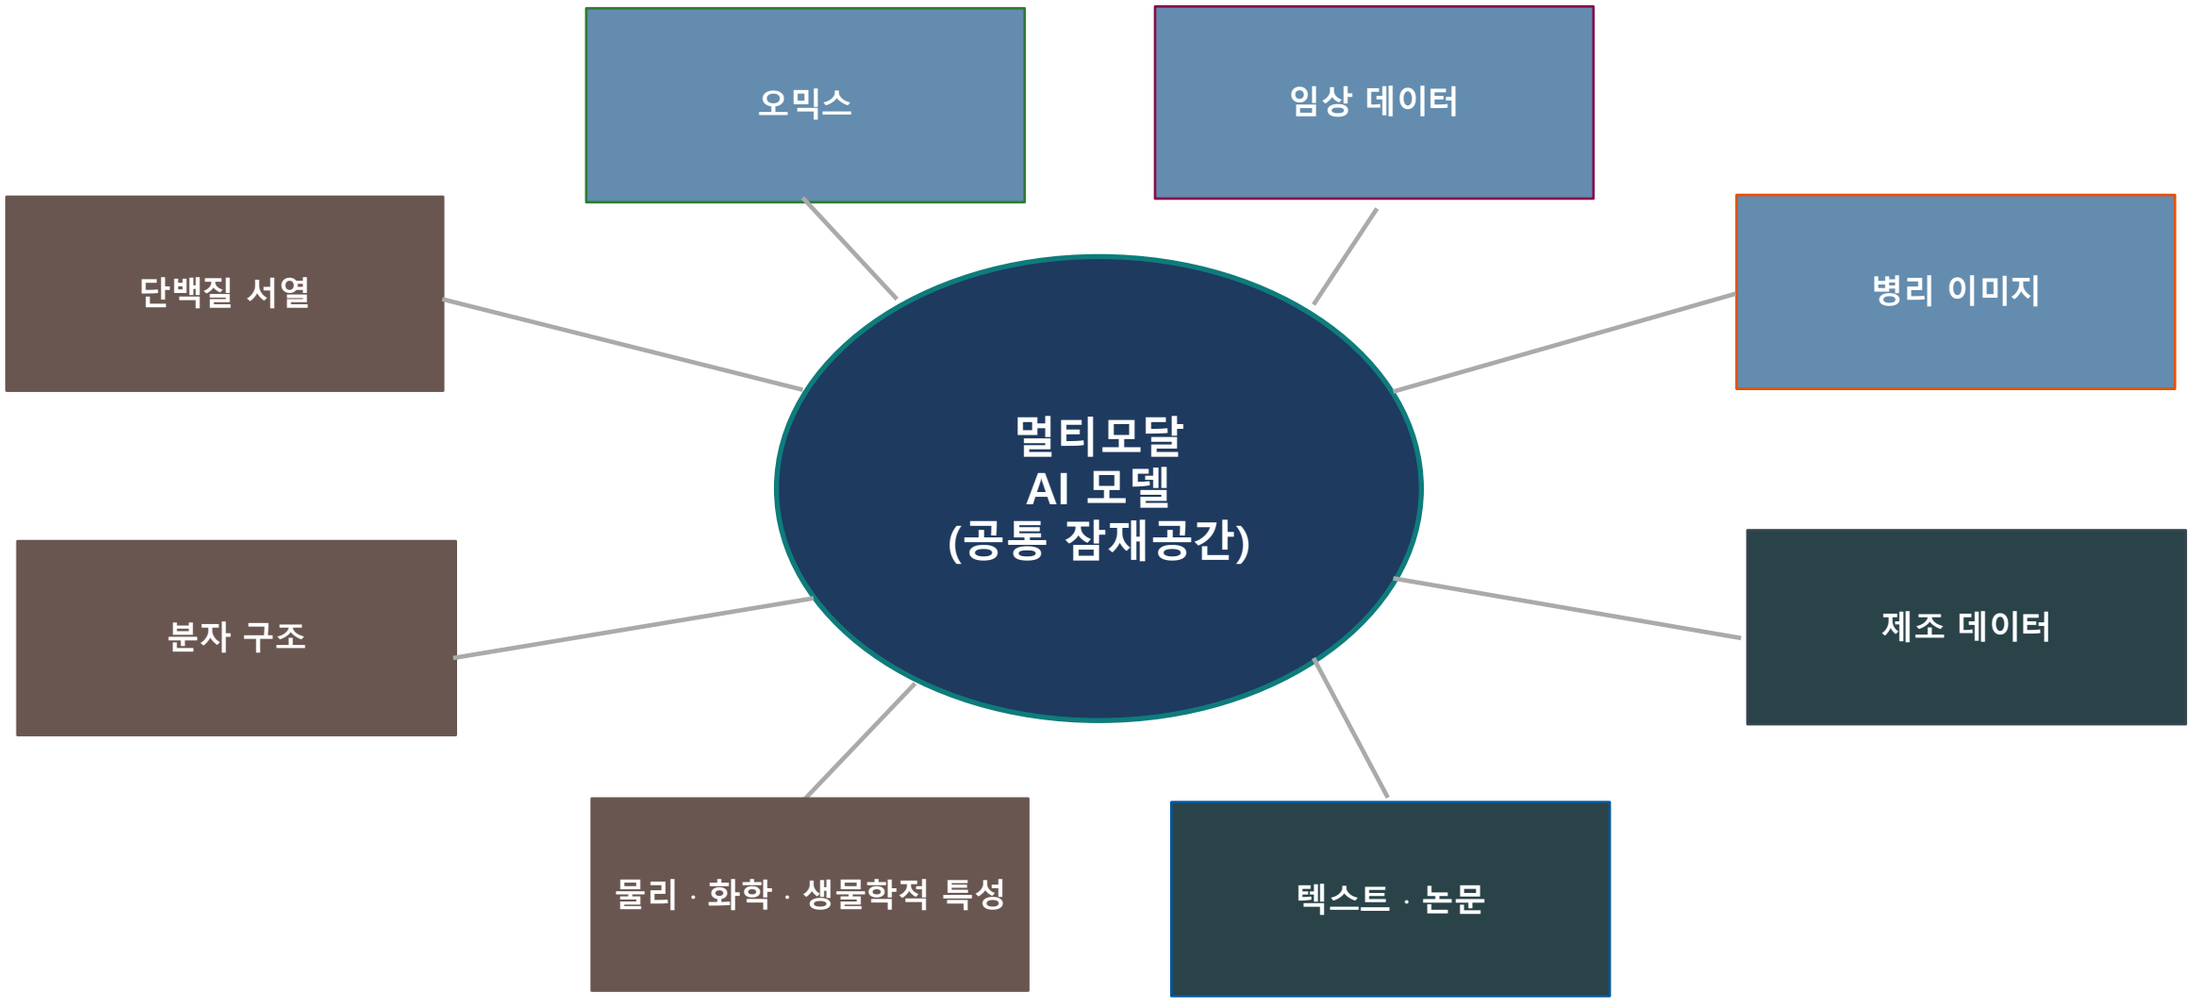
RAG

- 검색 증강 생성 (retrieval-augmented generation)
  - 모델이 외부 소스에서 관련 데이터를 검색할 수 있게 하여 컨텍스트를 다양하게 구성할 수 있다
  - 주어진 주제와 가장 관련이 높은 데이터를 사용한다 (장비 스펙 등)
  - 지식 베이스(계약서, 회의록 등)가 500 페이지를 넘지 않으면 롱 컨텍스트를 쓸 수 있다

Vector DB

- 벡터 DB에서는 벡터를 버킷, 트리, 그래프 구성한다
- 저차원 벡터를 사용하여 속도를 개선할 수 있다
- 유사 벡터 클러스터링을 사용하여 속도를 개선할 수 있다
- 데이터가 추가될 때마다 이론적으로 모든 vector를 다시 계산해야 하는 문제, 즉, 비용의 문제가 있다

멀티모달 AI



서로 다른 형식(mode)의 데이터를 공통 잠재공간에서 학습하여 모델 성능 향상

분자 표현법

- SMILES (Simplified Molecular-Input Line-Entry System)
  - Cn1cnc2N(C)C(=O)N(C)C(=O)c12 과 같이 분자를 문자열로 표현
- Descriptors
  - 몰질량, 구성 원자, 분배계수, 극성표면적 등 분자를 기술하는(describe) 수치 데이터들을 특성(feature)으로 사용(테이블 구조)
- Fingerprints
  - 분자가 가지고 있는 여러 특성 유무를 1, 0 패턴으로 표현 (화학적 지문)
  - 두 분자의 속성이 유사하면 fingerprints의 1, 0 발생 패턴이 유사
- Graph based

Molecule Representation

- 최근 Graph representation을 주로 사용한다

Acetic Acid

분자 표현형(Representation) 비교

- AI는 숫자만 이해한다
  - ① 기술자(Descriptor): 분자량 ·LogP ·TPSA 등 수치 표- 해석이 쉽고 물성 예측에 강함
  - ② 지문(Fingerprint): 부분구조 유무를 0/1 비트로 (Morgan/ECFP) — 유사도 검색 ·QSAR의 표준
  - ③ 그래프(Graph): 원자=노드, 결합=엣지로 표현, 구조 정보 보존
  - ④ 임베딩(Embedding): 사전학습 모델이 만든 벡터 표현형 사용 (ChemBERTa ·MoLFormer)
- 선택 기준
  - 물리화학적 물성(용해도 ·LogP) → 기술자 표현
  - 표적 결합 활성(QSAR) → 지문 또는 지문+기술자 결합
  - 구조 정보가 중요 → 그래프(GNN)
  - 데이터가 수십~수백 건으로 적을 때 → 파운데이션 모델 임베딩
  - 정답은 없다 — 교차검증으로 비교해서 선택하는 것이 원칙

화합물 Datasets

- PubChem
  - By National Institutes of Health from 2004 (non-curated)
  - 가장 규모가 크다 (거의 모든 화합물 정보를 포함)
  - curated dataset of 77 million SMILES
- ChEMBL
  - manually curated (and so high-quality) public database of bioactivity data
  - 1.9 m compounds, 12,000 targets from 1.1 M assays
- ZINC
  - by UCSF
  - molecules, annotated ligands and targets as well as the purchasability for 120 million "drug-like" compounds
  - 부분 데이터: ZINC-250k, ZINC Clean Leads collections

MoleculeNet

- 학습용 분자 데이터셋 (tox21, delany 등)
  - 양자물리학, 물리화학, 생물물리학, 생리학 등 범위의 데이터 제공
- ESOL 수용성 용해도, BBBP 투과성 예측 등

Lipinski's Rule-of-5

- Lipinski Rule (1997)
  - 구강투여될 만한 화합물인지 판단 (drug-like)
  - World Drug Index에서 2245개 화합물로부터 추출 (90%가 해당)
- Poor absorption or permeability when:
  - LogP (water partition coefficient, a measure of lipophilicity) is >5
  - molecular mass is >500 Da
  - the number of hydrogen-bond donors (OH plus NH count) is >5
  - the number of hydrogen-bond acceptors (O plus N atoms) is >10

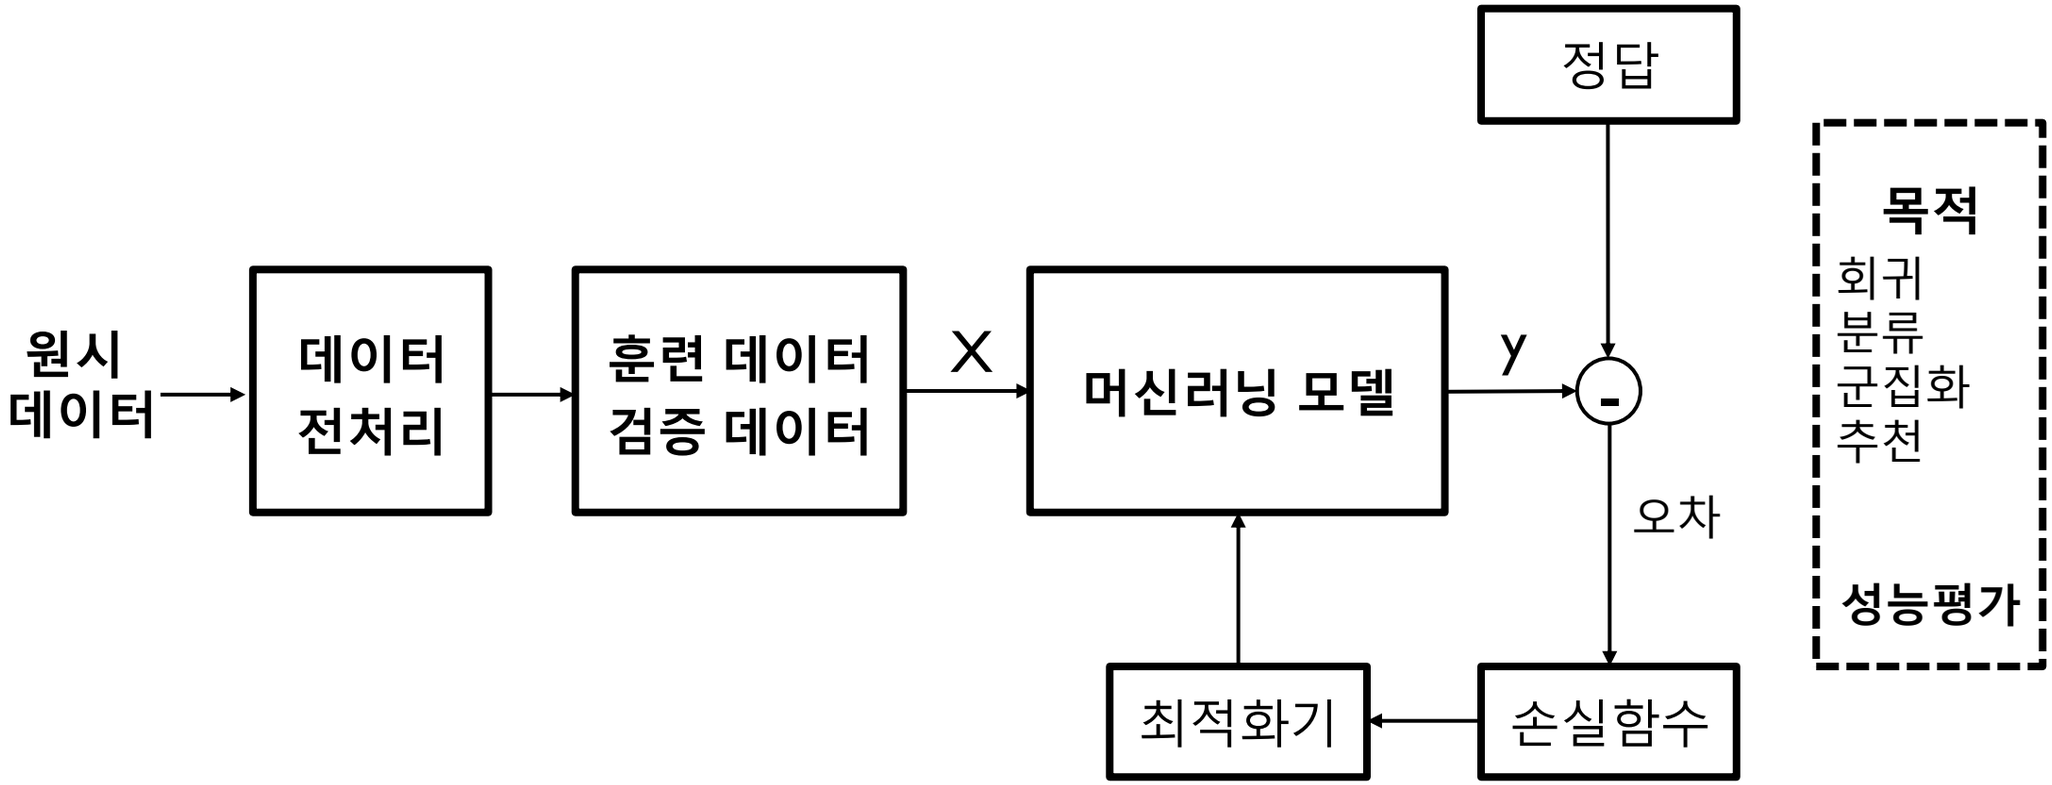
QED

- Quantitative Estimate of Drug-likeness (2012)
- From molecular properties for small molecule drugs

AI 구현 기술

머신러닝 모델 구현

- 데이터 전처리
  - 모델의 성능을 높이기 위해서 결측치 처리, 이상치 처리, 스케일링, 카테고리 인코딩 등을 수행하는 것
- 훈련/검증 데이터
  - 모델을 만드는 데는 훈련 데이터를, 성능을 검증하는 데는 검증 데이터를 사용한다



머신러닝 모델

머신러닝 유형		알고리즘	특 징
지도학습 (y가 존재)	선형 계열	선형 모델, SVM 로지스틱회귀	곱셈과 덧셈으로 점수를 구하고 이를 이용하여 회귀와 분류 예측
	신경망	MLP, CNN, RNN, Transformer Graph Network	매트릭스 연산을 기반으로 점수를 계산하며 활성화 함수 도입
	트리 계열	결정 트리, 랜덤포레스트, 부스팅	True/False 선택을 반복하여 회귀와 분류 예측 수행. 스케일링이 필요없다
	기타	kNN, 베이즈	특성 공간상의 거리를 기준, 또는 조건부 확률을 기준으로 예측
비지도학습 (y가 없음)	클러스터링	k-means, DBSCAN	특성 공간상 거리 또는 유사도를 기준으로 샘플을 그루핑
	데이터 변환	스케일링, 로그변환, 카테고리 인코딩	모델의 성능을 높이 위한 데이터 전처리
	차원 축소	PCA, t-SNE	계산량을 줄이고 모델 성능을 향상, 또는 시각화를 위한 차원 축소
	표현 학습	LLM 등 파운데이션 모델	입력 데이터를 latent vector로 표현하는 비지도 학습
강화학습		시행착오의 경험을 누적	샘플 입력마다 정답이 있지 않지만 최종적으로 달성해야 할 목표를 알려주고 보상을 통해 학습

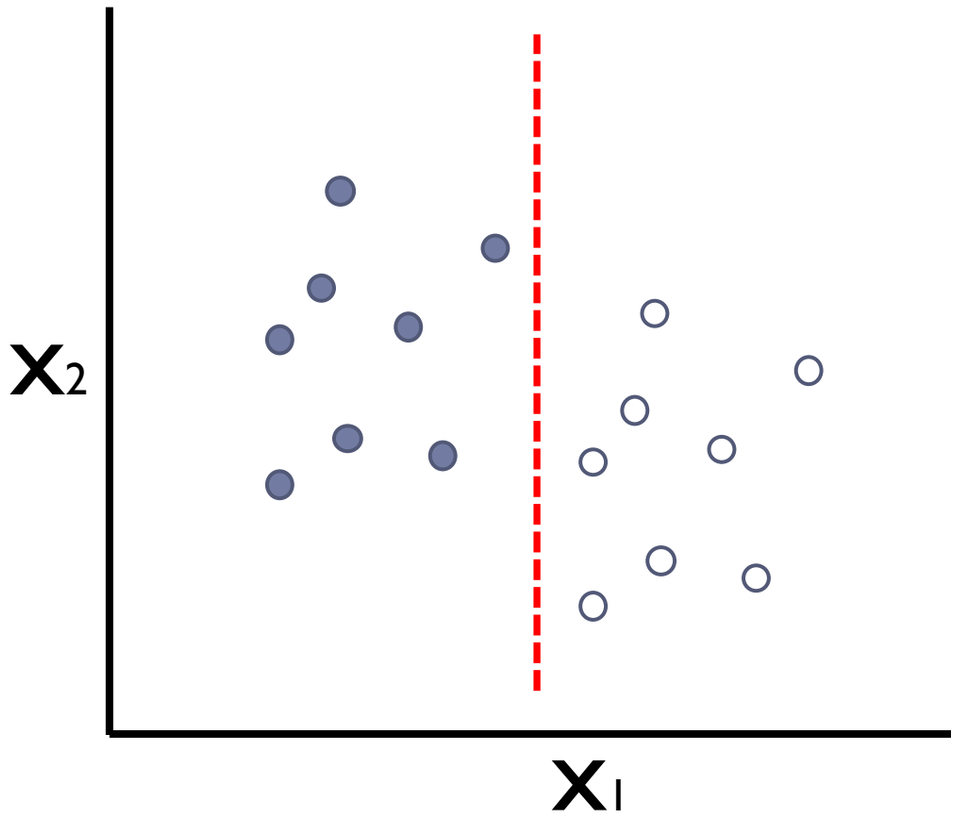
데이터 전처리

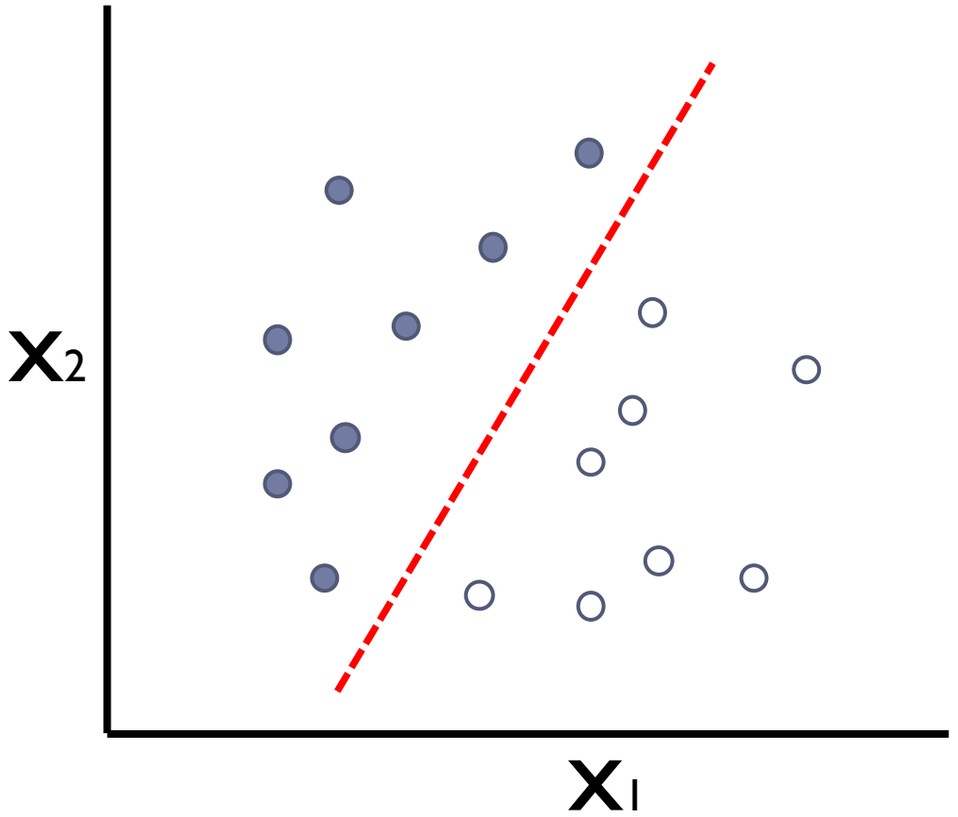
- 데이터 정제 (cleaning)
  - 빠진 값을 처리하거나 오류를 수정하는 것
- 이상치 처리
  - 비정상적으로 튀는 값(이상치)을 찾거나 제거하는 것
- 데이터 변환 (transformation)
  - 로그, 역수, 승수, 카테고리 변수를 적용하는 것
- 스케일링 (scaling)
  - 여러 데이터의 특성 값의 범위를 동일한 조건으로 조정하는 것
- 특성 선택과 차원 축소
  - 특성 중 일부를 선택하거나 특성을 조합하여 새로운 특성을 만드는 것
  - 주성분 분석(PCA): 머신러닝에 사용할 특성의 수를 줄이는 것
    - Principal components analysis

선형 회귀

- 선형 회귀(regression) y = wX + b

선형 분류





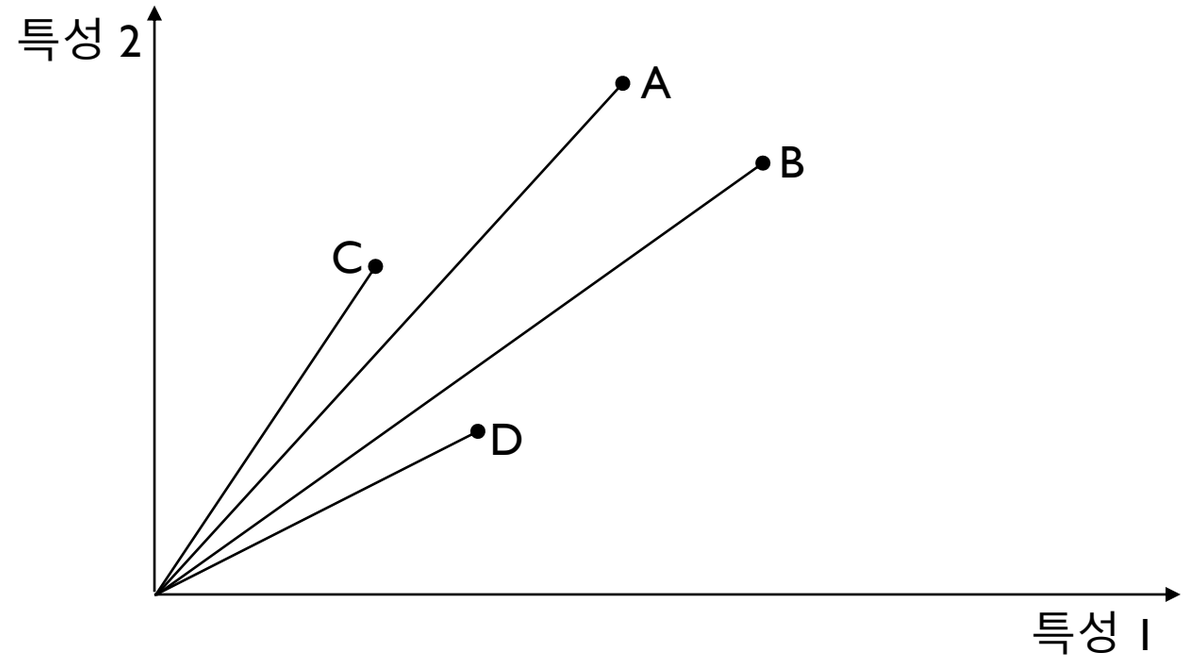
유클리디언 거리

- 기하학의 공간(space) 상의 직선 거리
  - 유클리디언 (Euclidean) 거리

- n 차원 공간상의 두 점의 거리

코사인(cosine) 유사도

- 공간상의 두 점이 만드는 각도를 기준으로 유사도를 측정하는 방법 (-1 ~ +1 사이의 값을 갖는다)
- 공간상 거리가 멀어도 두 점이 가리키는 방향이 같으면 서로 비슷하다고 보는 것



- A와 C가 가깝고 B와 D가 가깝다고 정의

자카드 유사도

- 어떤 두 항목이 겹치는 부분의 절대량만을 보지 않고, 두 항목의 공통 부분이 얼마나 많은지를 고려하여 이에 대한 상대적인 값을 유사도로 사용하는 것

- A, B, C가 각각 지난해 본 영화의 총 개수가 20편, 50편, 200편
- J(A,B) = 5 / (20+50-5) = 0.076
- J(A,C) = 10 / (20+200-10) = 0.047
- 즉, 0.076 > 0.047이므로 A와 B가 더 가깝다고 할 수 있음

결정트리

- 분류 모델
  - 하위 그룹에 가능하면 같은 종류의 샘플이 모이도록 한다
- 회귀 모델
  - 하위 그룹의 샘플의 분산(variance)이 적도록 나눈다

결정트리

- ***<u>한번에 한 특성</u>***씩을 대상으로 훈련 샘플을 (두개의) 그룹으로 나누되 각 그룹에 가능한 유사한 샘플들이 모이도록 한다

랜덤 포레스트

- Random Forest, 결정 트리의 성능을 개선한 방법
- 간단한 구조의 결정 트리(weak learner)를 수백개 만들고 각 결정 트리의 동작 결과의 평균치를 사용하는 방법
  - 랜덤 포레스트를 구성하는 약한 결정 트리를 만들 때 훈련 데이터의 일부만 사용하거나 특성의 일부만 무작위로 선택한다
- 이를 앙상블(ensemble) 방법이라고 하며 결정 트리 모델보다 좋은 성능을 얻는다

특성 중요도

- feature_importances_
  - 결정 트리 모델을 만든 후에, 어떤 특성이 결정 트리를 생성할 때 중요한 역할을 했는지 상대적인 비중을 파악할 수 있다
  - 내부 변수인 feature_importances_에서 확인할 수 있다

손실함수와 성능지표

- **손실함수**(loss function)는 모델을 훈련시킬 때 기준으로 삼기 위해서이다.
  - 모델은 손실함수를 최소화 하는 방향으로 학습한다
- **모델의 성능지표**는 이렇게 만든 모델이 궁극적으로 얼마나 잘 동작하는지를 평가하는 척도이다

회귀모델의 손실함수

- 회귀분석에서는 오차 자승의 합의 평균치(MSE: mean square error)를 손실함수로 주로 사용한다

  - N: 배치 크기

- 배치 크기, 학습률과 같은 설정 변수를 하이퍼파라미터라고 한다
  - **하이터파라미터**는 사람이 선택하는 값이며, 머신러닝 모델이 최적화 해야 하는 계수는 "**파라미터**"이다

회귀 성능 평가 지표

- 회귀모델의 성능 평가에는 R-squared가 사용된다.
- R-Sqaured,

- 위에서 는 실제 값, 는 예측 값, 는 샘플의 평균 값을 나타낸다
- 완벽한 회귀 예측 모델은. 값이 1이 된다

분류의 성능지표

- 분류에서는 정확도(accuracy)를 기본으로 측정하나 필요에 따라 다음과 같은 값을 추가로 측정해야 한다
- 컨퓨전 매트릭스를 사용한다
  - 정밀도 (precision)
  - 재현률 (recall)
  - F-1 점수
  - ROC
  - AUC

혼돈 매트릭스

- 혼돈 매트릭스(confusion matrix)란 분류의 결과가 잘 맞았는지를 평가하는 채점표와 같다
- 이진 분류의 경우 네 가지 경우의 수가 존재한다.

실제 \ 예측	p로 예측	n으로 예측
실제로는 p	True positive (TP)	False negative (FN)
실제로는 n	False positive (FP)	True negative (TN)

실제 \ 예측	p로 예측	n으로 예측
실제로는 p	7	3
실제로는 n	10	80

- accuracy= (6+80)/100=0.86, recall=(7/10)=0.7, precision=(7/17)=
  F1-score: recall과 precision의 조화 평균

분류의 손실함수

- 분류에서 예를 들어 정확도(accuracy)를 손실함수로 사용하면 다음과 같은 문제가 있다
  - **카테고리 분포 불균형**시 문제
  - 클래스 발생빈도가 다른 경우, 적게 발생하는 클래스를 잘 찾지 못한다
- 분류 모델에서는 이를 보완하기 위해서 크로스 엔트로피(cross entropy)를 손실함수로 사용한다

- m: 클래스 수

손실함수와 성능지표

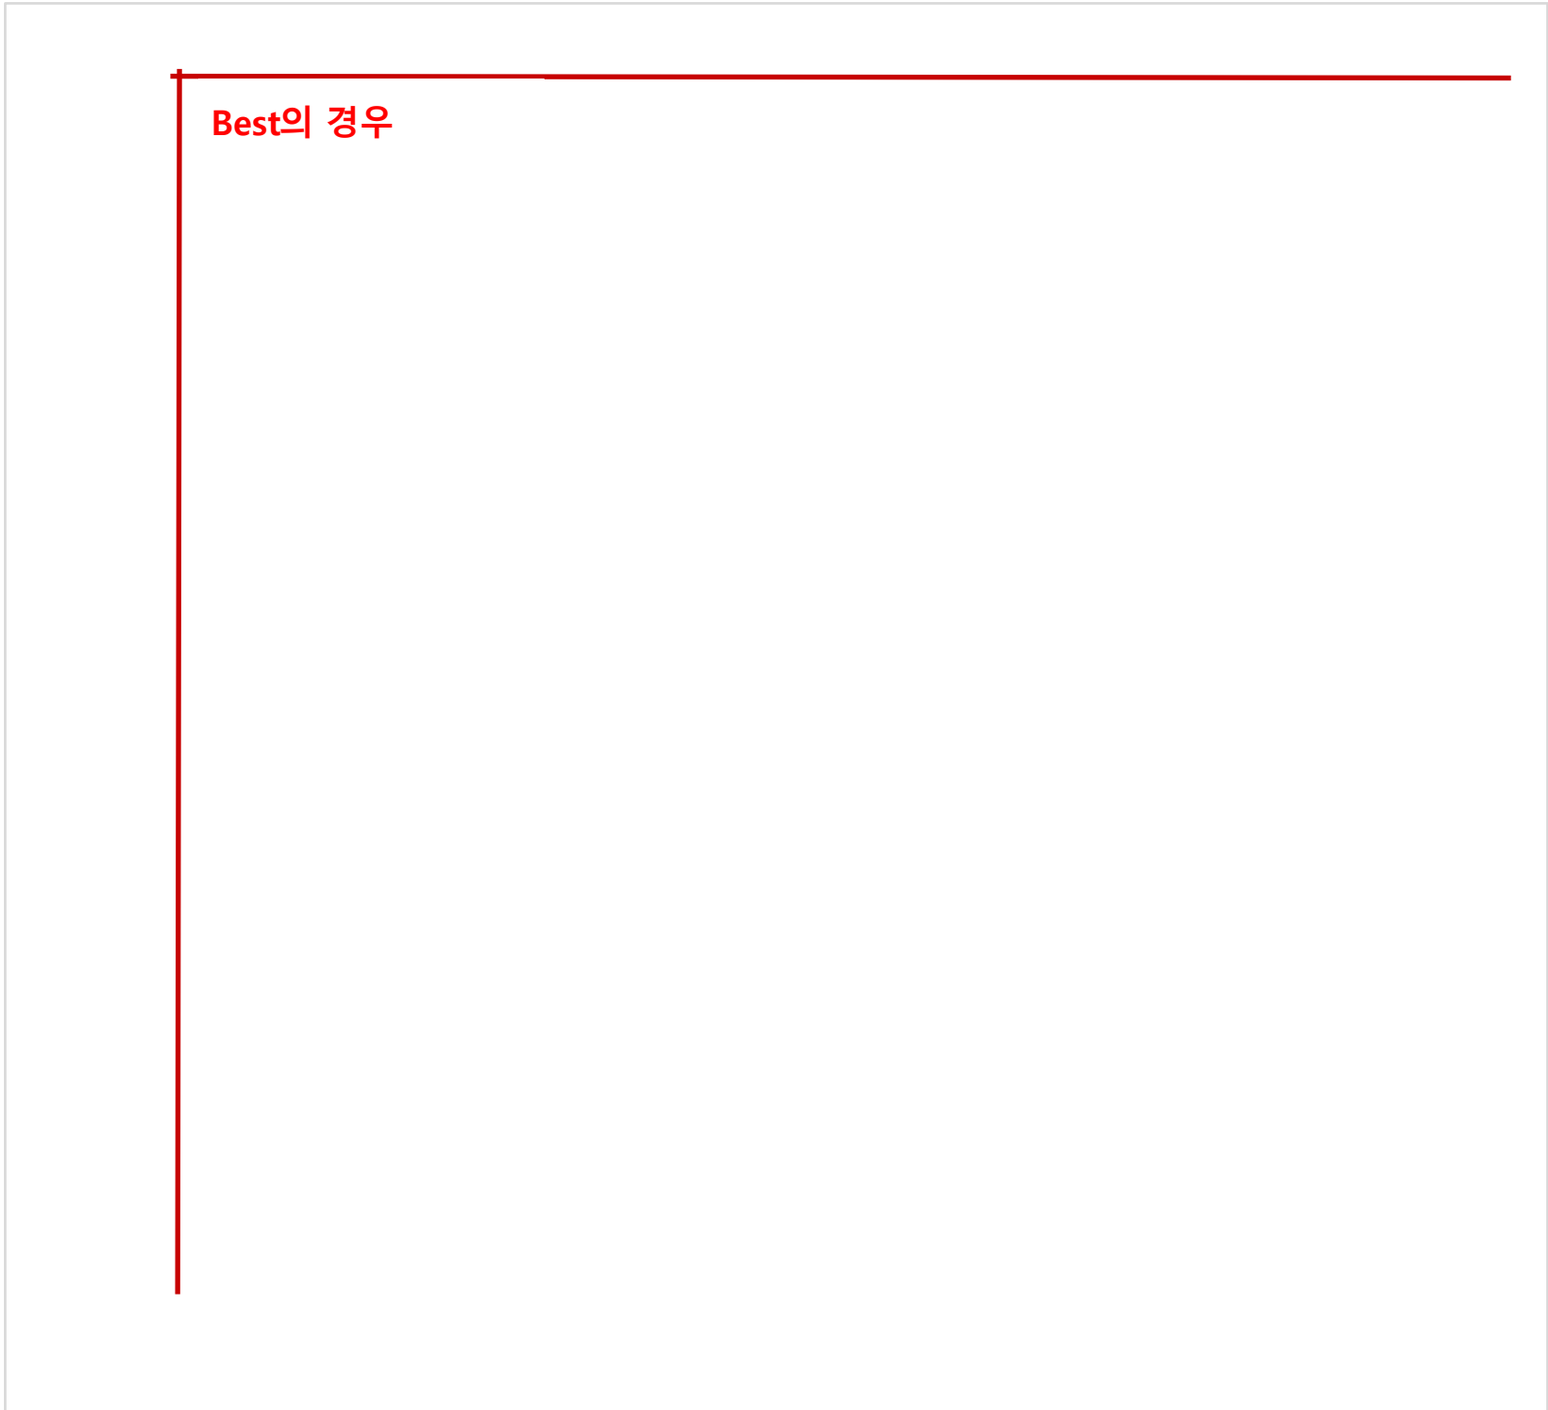
- 대표적인 손실함수와 성능 평가 지표
  - 분류에서는 정확도 외에 성능 지표로 정밀도(precesion), 재현률(recall), F1-지수 등이 추가로 사용된다.

	손실함수	성능평가지표
정 의	손실함수를 줄이는 방향으로 모델이 학습을 함	성능을 높이는 것이 머신러닝을 사용하는 목적임
회귀 모델의 대표적인 값	MSE (오차 자승의 편균치)	
분류 모델의 대표적인 값	크로스 엔트로피	정확도, 정밀도, 재현률, F1점수

순위 평가

- 분류를 예측한 ***순서를 고려한*** 평가 방식
  - 찾고자 하는 positive 샘플에게 높은 점수를 주었는지를 평가하는 것
- ROC 커브
  - Receiver Operating Characteristic
  - 예측 결과를 점수가 높은 순서대로 예측한 것이 실제 값과 얼마나 순서에 따라 잘 맞는지는 검증하는 2차원 그래프
  - (0,0)점에서 시작하여 정답을 맞추었으면 y축 위로 한 칸 이동, 정답을 맞추지 못했으면 x축 방향으로 한 칸 이동하며 종점은 (1, 1)이다
  - y축은 예측이 맞은 것을 나타내므로 true positive rate, x축은 예측이 틀린 것을 나타내므로 false positive rate라고 한다
- AUC(Area Under the Curve)
  - ROC 성능을 간단히 하나의 수치로 나타내기 위해서 ROC 그래프의 면적을 사용하는 것

ROC 그래프 예시



AUC(Area Under Curve)

- ROC 그래프의 면적을 계산
- 우수한 알고리즘일수록 초반에 y축 상단 방향으로 이동하므로 ROC 커브의 면적이 넓어짐

과대적합

- 모델이 훈련 데이터에 대해서만 잘 동작하도록 만들어져서 새로운 데이터에 대해서는 오히려 잘 동작하지 못하는 경우를 과대적합(over fitting)되었다고 한다
- 과대적합은 주어진 훈련 데이터를 너무 세밀하게 학습에 반영하여 발생하는 현상이다
- 머신러닝에서는 과대적합을 피해서 일반적으로 잘 동작하게 모델을 만드는 것이 매우 중요하다
  - 이를 모델의 일반화(generalization)라고 한다
- 일반화 방법
  - 모델을 단순하게 만든다(이를 규제화(regularization)라고도 한다)
  - 더 많은 훈련 데이터를 확보한다

과대적합 검증

- 훈련 데이터에 대한 성능과 검증 데이터에 대한 손실함수를 관찰한다

과대적합 검증

- 성능 비교

훈련, 검증, 테스트 데이터

데이터 분할과 데이터 누수

- 분할 방식이 성능을 좌우한다
  - 무작위 분할: 유사 화합물이 학습·평가에 나뉘어 들어가 성능이 부풀려진다
  - 스캐폴드 분할: 골격이 같은 분자를 클러스터링한다
  - 시간 분할: 과거로 학습해 미래를 예측해야 하는 경우
- 데이터 누수(Data Leakage) — 너무 좋은 성능은 의심하라
  - 예측 시점에 알 수 없는 정보가 입력에 포함된 경우
  - 흔한 사례: 결과와 사실상 같은 변수, 미래 정보, 전체 데이터로 전처리한 뒤 분할
  - 점검법: 현업 전문가와 확인하고 "이 값을 그 시점에 정말 알 수 있나"를 확인한다

로지스틱 회귀

- 로지스틱 회귀분석(logistic regression)은 임의의 범위를 갖는 선형적 값으로부터 이진 분류의 확률을 예측하는 모델

sigmoid

- 입출력의 관계를 S형 커브를 사용하여 선형값을 확률로 매핑할 때 사용되는 함수
- S 커브를 시그모이드 함수라고 한다

소프트맥스

- 이진 분류가 아니라 3개 이상의 클래스 중에 하나를 예측해야 하는 경우는 로지스틱 회귀를 사용할 수 없다
- 이때는 소프트맥스 (softmax) 함수를 이용한다
  - 각 클래스로 분류될 가능성을 나타내는 점수를 먼저 구하고 이 점수들을 사용하여 상대적인 확률의 비율을 구한다

소프트맥스

SVM

- 서포트 벡터 머신(Support Vector Machine, SVM)은 선형 모델을 개선한 것
- 기본 아이디어는 분류시에 경계면을 가능한 일반화 한 것
  - 분류시 샘플 집단 간의 거리를 가능한 멀리 나눌 수 있는 경계면을 찾는다 (Margin을 최대화 하는 경계면을 찾는 것)

딥러닝

MLP (Multi Layer Perceptron)

- 입력 데이터에 가중치를 곱하여 중간 출력을 만들고 이 중간 출력에 다시 가중치를 곱하여 다음 계층의 입력으로 사용하는 구조

중간층

입력층

출력층

활성화 함수

- MLP 각 계층에서, 가중합을 구한 후에 활성화 함수 (activation function)를 통과시킨다
- 이는 생물학적인 뉴런의 동작을 모방하여 비선형적인, 메모리 기능을 갖게 한 것

활성화 함수 종류

MLP 예

- 히든 계층이 6개인 예 (MLP는 2개 층만 사용해도 동작한다)

Convolution Neural Network

- 아래와 같이 임의의 크기와 모양을 가진 이미지 판독에서는 MLP가 동작하지 않는다
  - MLP에서는 입력신호 전체를 한번에 다룬다
- 합성곱 신경망 (Convolution Neural Network, CNN)은 이를 개선하였다

CNN

CNN 동작

- 합성곱동작
- 다층 필터링

최대풀링(max pooling)

- 특정한 패턴이 공간상의 어느 위치에 있든 이 활성값이 다음 단계로 넘어가면서 좌우로 조금씩 움직일 수 있다
- 풀링은 과대적합을 해소하는 데에도 기여한다

이미지 인식

드롭아웃

- 랜덤하게 신경망 유닛을 선택하여 신호를 전달하지 않는 방법
- 입력과 출력간의 특정 관계를 기억하지 못하게 한다
- 드롭아웃은 학습을 하는 동안에만 적용되다

전이학습 (transfer learning)

- 다른 곳에서 만든 신경망 모델을 재사용하는 것
- 학습시간도 줄일 수 있고 적은 데이터로도 성능이 좋은 모델을 만들 수 있다

전이 학습

Detect, Segment, Pose

Object Detection

- Confidence score

Object Segmentation

Object Segmentation

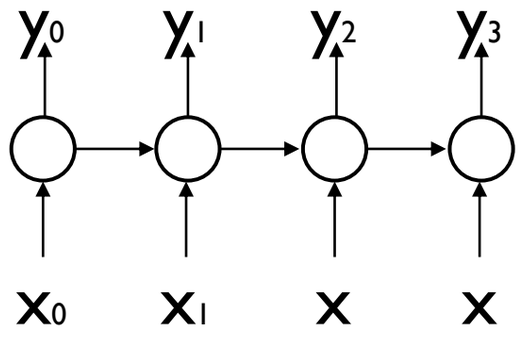
Cell Segmentation

YOLOv8 detect 성능

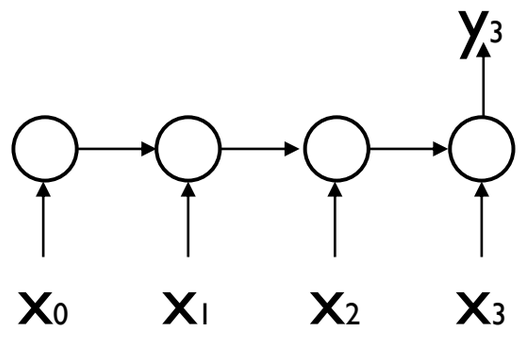
RNN의 구조

- 위 표현에서 활성화 함수와 bias는 생략됨
- 상태값 h를 다음 스텝에 사용한다
- U,V,W는 i의 함수가 아니라 모든 스텝에서 같은 모양을 갖는다

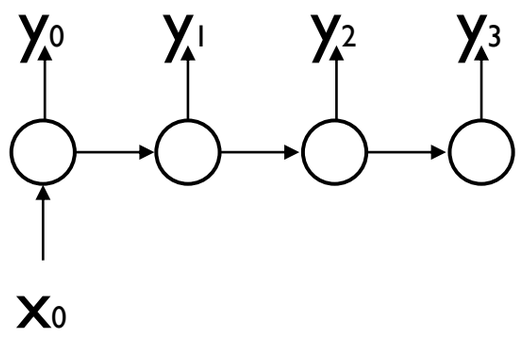
RNN 이용 형태



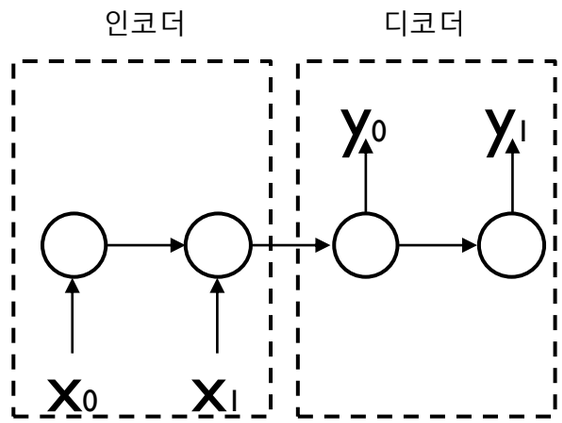
(a)



(b)



(c)



(d)

LSTM

- 망각 게이트:
  - 시그모이드를 적용하여 결과가 1이면 이전의 내부 상태 값을 모두 그대로 통과, 결과가 0이면 모두 망각을 수행 (중간 값은 통과 확률)

Graph Network

- Distill
- 그래프에 포함되는 정보 종류

Adjacency/Feature Matrix

- adjacency matrix
  - node 간의 관계(edge)를 표현하며 아래와 같이 방향성은 없는 경우 대칭적이다
- feature matrix
  - node에 담긴 정보를 나타내며, 아래의 경우 특성이 3개라고 가정함 (색을 구분)

그래프 컨볼류션

- edge로 연결된 node끼리의 정보 교환을 표현하는 방법
  - 주변 node의 정보를 spatial 하게 얻어 정보를 업데이트하는 방법
- 이미지 2D 콘볼류션과 그래프 콘볼류션의 차이

- (예) 2번 node를 업데이트할 때는 1,3,4 node를 사용하지만 다른 node는 2번 node만을 사용한다

Transformer

- Seq2seq(2014) 모델을 개선하는 모델
  - Seq2seq는 구글번역에 사용(2016)
  - 입력을 처리하는 인코더와 출력을 생성하는 디코더로 구성

- Seq2seq 모델의 한계
  - Latent vector 표현형의 한계
  - 긴 토큰 처리의 한계

트랜스포머

Transformer

- 어텐션: café를 디코딩할 때 주의해서 볼 내용은?
  - RNN 구조에서 동작 seq2seq 모델 사용

- **셀프 어텐션**: 입력 전체 토큰에 대해 각각 수행하는 어텐션
  - **트랜스포머**는 어텐션(Attention) 기법을 사용한다

가상 스크리닝

- 두가지 전략
  - 리간드 기반(LBVS): 알려진 활성물질과의 유사도 ·약효단 ·QSAR — 구조 없이 가능, 매우 빠름
  - 구조 기반(SBVS): 표적 3D 구조에 도킹 — 느리지만 새로운 골격(scaffold hopping) 발견 가능
- 실전 적용
  - 라이브러리(수백만) → 유사도 → 약물다움 ·PAINS 필터 → QSAR 활성예측 → 도킹 → 실험 검증(수십 개)
    - PAINS(Pan-Assay INterference compoundS): 여러 분석에서 "상습적 위양성 화합물", 미리 걸러내야 한다
- 성능 평가 — 정확도가 아니라 농축도
  - EF(Enrichment Factor, 농축도) = 상위 x% 안의 활성 비율 ÷ 전체 활성 비율. EF=1이면 무작위 선택 (실전에서는 10~50)
  - ROC-AUC와 함께 보고하며, 실무에서는 '상위 1%에 활성이 얼마나 모였는가'가 핵심

분자 도킹 (물리 계산 → 딥러닝)

- 도킹: 자세 탐색(search) + 점수 계산(scoring)
  - 결합에너지(kcal/mol)는 음수로 클수록 강한 결합 — 입체 상보성 ·소수성 · 수소결합 – 회전 자유도 손실
  - 절차: 수용체 ·리간드를 PDBQT 전처리(전하, 원자유형) → 결합부위에 탐색 상자 지정 → 도킹 → 상위 자세 분석
- 실험 검증 - 재도킹(Redocking)으로 실험
  - 결정 구조의 리간드를 다시 도킹해 실험 자세 재현 확인 (RMSD < 2 Å)
  - 재현하지 못하는 설정으로 스크리닝하면 결과를 신뢰할 수 없다 (> 3)
- 점수의 한계 – 확인 필요
  - 도킹 점수는 결합 자세 예측에는 강하지만 활성 예측은 약함
  - 리간드 효율(LE = –점수 / 무거운 원자 수)로 큰 분자의 과대평가(접촉 면적 증가 효과)를 보정 (> 0.3)
  - AlphaFold3 ·Boltz-2(단백질 구조와 결합을 한번에 예측)

	탐색	채점	특징
AutoDock Vina	물리 기반	물리 기반 수식	검증된 표준, 가볍고 빠름
GNINA	물리 기반	딥러닝 CNN	Vina 의 약점만 교체한 현실적 개선
DiffDock	딥러닝 생성	딥러닝	접근 자체가 다름, 결합부위 지정 불필요

단백질 구조 예측의 신뢰도

- pLDDT (0~100): 잔기별 '국소 구조 ' (부품) 신뢰도
  - predicted Local Distance Difference Test
  - 90 이상 = 측쇄까지 신뢰 / 70~90 = 주사슬 신뢰 / 50~70 = 주의 / 50 미만 = 무질서 영역 가능성
  - PDB 파일의 B-factor 자리에 저장하여 바로 색으로 확인 가능
- PAE (Å): 두 부위의 '상대적 배치 ' (조립) 신뢰도
  - Predicted Aligned Error
  - 잔기 i를 기준으로 맞췄을 때 잔기 j 위치의 예상 오차 (모든 아미노산 쌍에 대해서 계산)
  - 도메인 간 배치·복합체 해석에는 pLDDT보다 PAE
  - 복합체는 ipTM·pTM도 함께 확인

pTM (predicted TM-score)	**전체 구조**의 접힘이 맞는가 (0~1)	0.5 넘으면 큰 틀은 맞음
ipTM (interface pTM)	**두 사슬이 맞닿는 면**의 예측이 맞는가	**0.8 이상이면 신뢰**, 0.6 미만이면 틀렸을 가능성 높음

단백질 구조 예측의 신뢰도

- 신약설계에서의 판단 기준
  - (평균치가 아니라) 결합 pocket 잔기의 pLDDT가 90 이상이면 예측 구조로도 도킹 시도 가능
  - 예측 구조는 리간드 결합에 따른 구조 변화(induced fit)를 반영하지 못한다
    - 약이 없는 상태(apo) 의 구조를 예측은 실제 약이 들어오면 모양이 변한다
    - 곁사슬이 비켜주고, 홈이 벌어진다
    - 숨은 주머니(cryptic pocket) : 약이 올 때만 열리는 공간
- 약이 있을 때의 실험 구조(holo)가 있으면 실험 구조가 우선
  - 예측은 실험치가 없을 때의 방법

신약 타겟 발굴 — 근거의 통합

- 좋은 표적의 조건
  - 질병과의 인과적 연관, 조절 가능성(druggability), 안전성(정상 조직 영향), 임상적 미충족 수요
- 근거 유형과 데이터
  - 유전학: GWAS·희귀변이·체세포 돌연변이: 유전학적 근거가 있는 표적은 임상 성공률이 약 2배
  - 발현(오믹스): RNA-seq·단백체·단일세포: 환자 조직에서의 이상 발현
  - 네트워크: 단백질 상호작용(STRING)의 허브, 신호경로 위치
  - 기능 검증: CRISPR 스크린(DepMap): 없애면 암세포가 죽는지의 정보
- 주의: 과발현 ≠ 의존성
  - 발현이 높다고 표적이 되는 것은 아니다 (예: TNBC의 EGFR은 과발현되지만 항-EGFR 임상은 대부분 실패)
  - Open Targets 같은 통합 플랫폼의 점수는 '가설 생성 도구'이며, 기능 검증으로 확인해야 한다

생성형 분자 설계의 평가 지표

- 생성 모델은 많이 만드는 것'이 아니라 '쓸만한 것을 만드는 것
  - 유효성(Validity): RDKit이 파싱 가능한 화학적으로 올바른 분자 비율
  - 고유성(Uniqueness) ·신규성(Novelty): 중복이 아닌가, 학습 데이터에 없던 분자인가
  - 다양성(Diversity): 생성 분자 쌍의 평균 (1 - Tanimoto 유사도), 0.7~0.9가 적정
  - QED(약물다움 0~1) ·SA score(합성 난이도 1~10, 낮을수록 쉬움)
- 생성 → 필터 깔때기
  - 대량 생성 → 유효성 ·중복 제거 → Lipinski ·QED → 합성가능성 → QSAR 활성예측 → 도킹 → 화학자 검토
- 현실과 한계
  - 온도(temperature)가 높으면 다양해지지만 유효성 ·품질은 떨어진다
  - 점수만 높이는 분자(reward hacking)가 생길 수 있어 다중 목적 최적화와 전문가 검토가 필수

ADMET 예측과 공개 AI 툴

- ADMET: 약이 몸에서 어떻게 움직이는가
  - 흡수(A)·분포(D)·대사(M)·배설(E)·독성(T) — 임상 실패의 큰 비중을 차지하는 요인
  - 핵심 항목: 용해도, 장관흡수(HIA), 생체이용률, BBB 투과, P-gp 배출, CYP 저해, hERG 심장독성, DILI 간독성
- 직접 만들지 않고 가져다 쓰기
  - ADMET-AI (Stanford): TDC 41개 데이터셋 학습, pip 설치 한 줄로 104개 항목 예측 + 승인약물 대비 백분위 제공
  - SwissADME·pkCSM(웹), DeepPK 등 — 후보물질 1차 선별에 활용 가능
- 해석 원칙
  - 절대값보다 순위와 백분위로 해석하고, 적용 범위를 벗어난 분자는 신뢰하지 않는다
  - 높다고 항상 나쁜 것이 아니다 — 뇌 전이 치료제는 BBB 투과가 높아야 유리

실습 예제

- 01 · Colab·LLM 코딩과 분자 데이터 다루기
  - Colab 사용법과 "문제 정의 → LLM에게 코드 요청 → 실행·검증" 워크플로우를 익힌다. SMILES로 분자를 표현하고 RDKit으로 기술자·분자지문·그래프 3가지 표현형을 만들어, AI가 분자를 '숫자'로 이해하는 방식을 체험. (ESOL 1,128 분자)
- 02 · 머신러닝 기초 — 회귀·분류와 성능 평가
  - MAE·RMSE·R^2와 혼동행렬·정밀도·재현율·F1·ROC-AUC를 손으로 계산한 뒤 코드로 확인. 용해도 예측(회귀)과 뇌 투과 예측(분류)으로 7종 모델을 비교하고, 과대적합을 확인합니다. 이후 모든 예제의 공통 기초.
- 03 · 용해도 예측 회귀 모델 (QSAR)
  - 기술자·지문·결합 등 표현형별 성능을 비교하고 전문가 경험식(Delaney)과 비교. 크게 틀린 분자를 찾아 원인을 분석하고, 학습 데이터와 닮지 않은 분자는 예측을 믿을 수 없다는 적용 범위(Applicability Domain) 개념을 데이터로 확인.
- 04 · 독성 예측 분류 모델 (Tox21)
  - NIH·EPA·FDA 공동 Tox21 데이터로 미토콘드리아 독성을 예측. 양성이 5~15%뿐인 불균형 데이터에서 정확도의 함정을 확인하고, 비용 기반으로 경보 임계값을 정하는 법과 독성 구조경고(toxicophore) 해석을 다룬다.

실습 예제

- 05 · 딥러닝 모델 유형 비교 (MLP·CNN·RNN·GNN·Transformer)
  - 같은 BBB 투과 문제를 MLP(지문)·1D-CNN과 LSTM(SMILES)·GCN(분자 그래프)·ChemBERTa(사전학습) 5가지로 풀어 비교. 손실함수·에폭·조기종료 등 딥러닝 학습 과정과, 작은 데이터에서는 전통 ML이 여전히 강하다는 사실을 함께 배운다.
- 06 · 모델 최적화 — 특성공학·교차검증·튜닝
  - ChEMBL BACE-1 데이터로 표현형 선택, 특성 선택, Grid·Random·베이지안(Optuna) 튜닝을 비교합니다. 신약개발의 필수인 스캐폴드 분할로 '새로운 골격'에 대한 현실적 성능을 측정하고, SHAP으로 예측 근거를 설명.
- 07 · 가상 스크리닝과 분자 도킹
  - 유사도 검색 → 약물다움·PAINS 필터 → QSAR → 도킹의 깔때기를 구현하고 농축도(EF)로 성능을 평가. AutoDock Vina로 BACE-1에 실제 도킹을 수행하고, 재도킹 RMSD로 프로토콜을 검증한 뒤 결합 자세를 3D로 확인.
- 08 · 단백질 구조 예측 (AlphaFold·ESMFold·ESM-2)
  - AlphaFold DB에서 예측 구조를 받아 pLDDT와 PAE를 해석하고, 실험 구조와 RMSD를 직접 계산해 정확도를 확인. ESMFold로 서열에서 구조를 예측하고, 단백질 언어모델 ESM-2로 KRAS 전체 변이 지도를 만들어 AlphaMissense와 비교.

실습 예제

- 09 · 신약 타겟 발굴 — 오믹스·네트워크 데이터
  - Open Targets로 질병-유전자 근거를 모으고, TCGA 유방암 환자 981명의 전사체로 차등발현을 분석. STRING 단백질 네트워크의 허브와 약물개발 가능성(tractability)을 통합해 삼중음성유방암 표적 후보 순위를 만든다.
- 10 · 생성형 AI 기반 신약 분자 설계
  - ZINC로 사전학습된 SMILES 생성모델로 새 분자를 설계하고, 유효성·고유성·신규성·다양성·QED·합성난이도(SA)로 품질을 평가. 생성 → 필터 → QSAR 활성예측으로 이어지는 '생성형 + 예측형 AI' 결합 파이프라인을 경험.
- 11 · 파운데이션 모델과 공개 AI 툴 활용
  - 모델을 직접 만들지 않고 공개 툴로 푸는 방법. ADMET-AI로 104개 약물성 항목을 한 번에 예측하고, ChemBERTa·MoLFormer 임베딩과 파인튜닝을 비교하며, ChEMBL·PubChem API와 LLM 연구 조수 활용까지 다룬다.

Q & A